Uniwersytet Warszawski
Wydział Matematyki, Informatyki i Mechaniki

Imię i nazwisko
Nr albumu: nralbumu

Intuicyjny język wyszukiwania TQL (Tablets Query Language)

Praca magisterska
na kierunku INFORMATYKA

Praca wykonana pod kierunkiem
dra Roberta Dąbrowskiego
Instytut Informatyki

czerwiec 2010

Oświadczenie kierującego pracą

Potwierdzam, że niniejsza praca została przygotowana pod moim kierunkiem i kwalifikuje się do przedstawienia jej w postępowaniu o nadanie tytułu zawodowego.

Data Podpis kierującego pracą

Oświadczenie autora (autorów) pracy

Świadom odpowiedzialności prawnej oświadczam, że niniejsza praca dyplomowa została napisana przeze mnie samodzielnie i nie zawiera treści uzyskanych w sposób niezgodny z obowiązującymi przepisami.

Oświadczam również, że przedstawiona praca nie była wcześniej przedmiotem procedur związanych z uzyskaniem tytułu zawodowego w wyższej uczelni.

Oświadczam ponadto, że niniejsza wersja pracy jest identyczna z załączoną wersją elektroniczną.

Data Podpis autora (autorów) pracy

Streszczenie

Sumerologia jest dziedziną badań nad antycznym językiem Sumerów, w której kluczowym zagadnieniem jest przeszukiwanie dużych zbiorów informacji zapisanych na odnalezionych tabliczkach sumeryjskich.

W pracy przedstawiono definicję przeznaczonego dla sumerologów intuicyjnego języka przeszukiwania zbiorów tabliczek (Tablets Query Language) wraz z jego przykładową implementacją opartą na relacyjnej bazie danych.

Celem tej pracy jest stworzenie języka zapytań intuicyjnego dla sumerologów, stanowiącego znaczące uproszczenie w stosunku do SQL dzięki wprowadzeniu pojęć naturalnych dla rozważanej dziedziny. Jednocześnie TQL nadal pozwala na tworzenie skomplikowanych zapytań wyszukujących, natomiast nie udostępnia funkcji tworzących i modyfikujących bazę. Można go rozszerzać i zmieniać tak, by mógł służyć też do innych zastosowań.

Słowa kluczowe

Dziedzina pracy (kody wg programu Socrates-Erasmus)

11.3 Informatyka

Klasyfikacja tematyczna

H. INFORMATION SYSTEMS
H.2. DATABASE MANAGEMENT
H.2.3 Languages

Tytuł pracy w języku angielskim

Intuitive query language TQL (Tablets Query Language)

Spis treści

Wprowadzenie

Sumerolodzy posiadają bazę danych składającą się z prawie 50 tys. tabliczek sumeryjskich w wersji elektronicznej. Potrzebują prostego i intuicyjnego języka służącego do ich wyszukiwania, który jak najmniej będzie ograniczał siłę wyrazu, a jego wykorzystanie będzie powodowało jak najmniejszy narzut czasowy.

Istnieją też inne grupy ludzi potrzebujące podobnego języka (np. językoznawcy). Większość programów ułatwiających tworzenie zapytań jest skomplikowana, daje ograniczone możliwości lub jest przystosowana głównie do przetwarzania danych liczbowych. Tablets Query Language rozwiązuje te problemy: jest prosty i intuicyjny, przystosowany głównie do tekstów, minimalnie zmniejsza siłę wyrazu oraz łatwo go rozbudowywać.

Język TQL jest nakładką na inne języki (m.in. SQL). Dla każdego z nich, w zależności od reprezentacji danych, należy skonstruować translator, którego zadaniem będzie przetłumaczenie zapytania. W ramach niniejszej pracy przedstawione zostaną dwa przykładowe translatory.

Rozdział 1

Podstawowe pojęcia

1.1. Definicje

Sumerolodzy - ludzie, którzy zajmują się odczytywaniem pisma klinowego w języku sumeryjskim. Na potrzeby tej pracy to pojęcie jest rozszerzone do wszystkich ludzi zajmujących się odczytywaniem tabliczek sumeryjskich i wyciąganiem z nich wiedzy historycznej.

Tabliczka - w tej pracy tabliczka będzie oznaczała tabliczkę sumeryjską w wersji elektronicznej (chyba, że zostanie zaznaczone inaczej). Dla rozróżnienia, kiedy będziemy mówić o "prawdziwej", glinianej tabliczce, będziemy używać pojęcia **gliniana tabliczka**

Prowiniencja - pojęcie używane przez sumerologów, oznacza miejsce pochodzenia/znalezienia glinianej tabliczki

Kliny - znaki występujące na glinianych tabliczkach.

Odczyty - sposób transkrypcji klinów, występuje na tabliczkach elektronicznych.

Pieczęć - część tabliczki zawierająca znak rozpoznawczy autora

Rozdział 2

Wcześniejsze rozwiązania

W chwili obecnej nie ma czegoś takiego jak język dostosowany do potrzeb sumerologów. Są strony internetowe oferujące wyszukiwanie, jak np.

- **The Cuneiform Digital Library Initiative** (http://cdli.ucla.edu) - największa znana nam baza tekstów sumeryjskich, wyszukiwanie po praktycznie wszystkich możliwych parametrach, choć trochę mało wygodne. Brakuje wyjaśnienia jak używać "Advanced search syntax"
- **The Electronic Text Corpus of Sumerian Literature** (http://etcsl.orinst.ox.ac.uk/) - baza znacznie mniejsza, zawiera głównie teksty literackie. Wyszukiwanie mało rozbudowane.

Rozdział 3

Dziedzina problemu

Głównym pojęciem jest tabliczka. Ma ona swoje metadane i treść. Tabliczka jest rozumiana dwojako - jako fizyczna tabliczka gliniana zapisana klinami lub jako tabliczka w formie cyfrowej zapisana odczytami. Może ona zawierać elementy znaczące takie jak imię jakiejś osoby, liczba, jednostka (np. przy opisywaniu wypłat), miejsce, data, imię bóstwa. Część tych elementów da się przetłumaczyć na współczesny język (np. jednostki przeliczyć na SI, datę na datę liczbową BC). Gliniane tabliczki są zapisywane z różnych stron (od góry, z przodu, z tyłu itp). Poza tym zawierają pieczęcie - fragmenty tekstu po prostu odbijane na tabliczce (coś jak nasza pieczątka).

Sumerolodzy rozpoznają tabliczki po publikacjach - wiedzą mniej więcej o co chodzi jak widzą publikację.

Odczyty zawarte w cyfrowym zapisie tabliczki są wariantem tłumaczenia z klinów. W cyfrowej wersji nie ma klinów, stąd też możliwe są pomyłki w tłumaczeniach, które ciężko zweryfikować. Są też uszkodzone fragmenty, które zostały cyfrowo zapisane w najróżniejszej formie (np. po niemiecku “Tutaj miałem problem, ale chyba powinno być «xxx»” (-;)

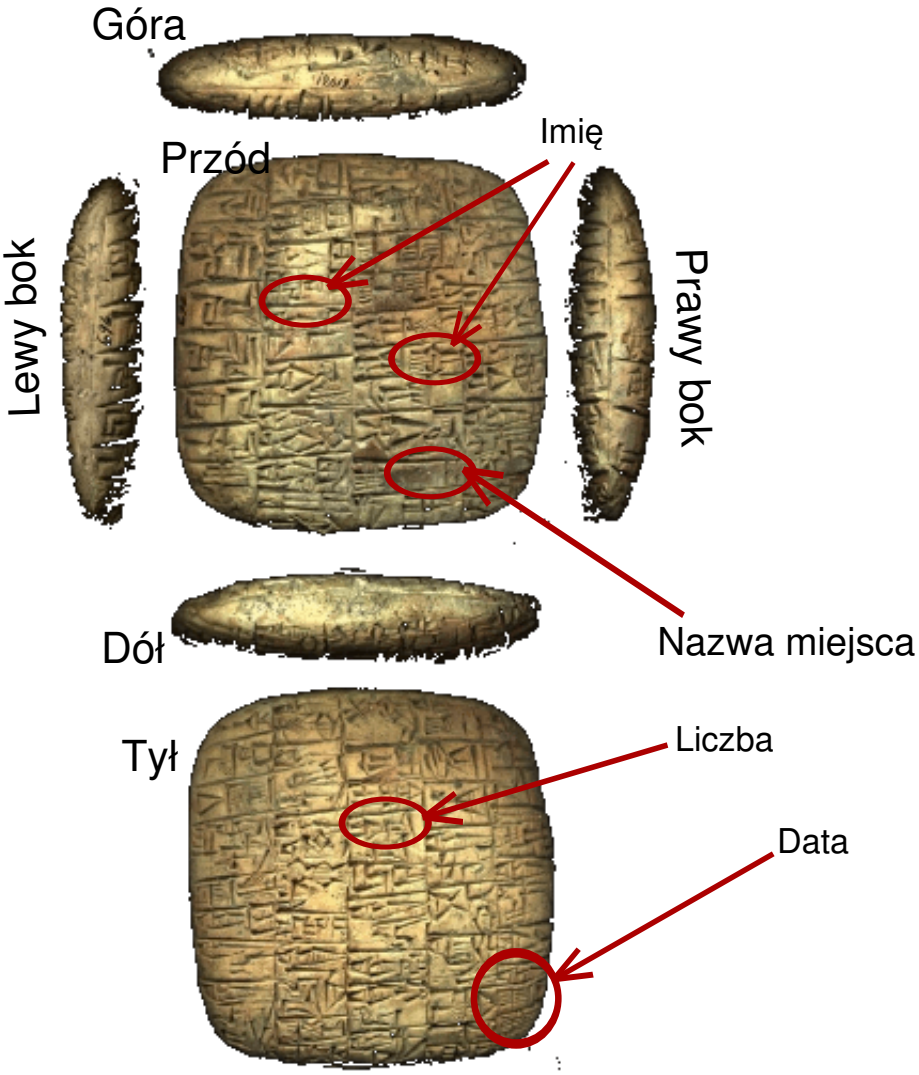

Rysunek 3.1: Gliniana tabliczka - struktura

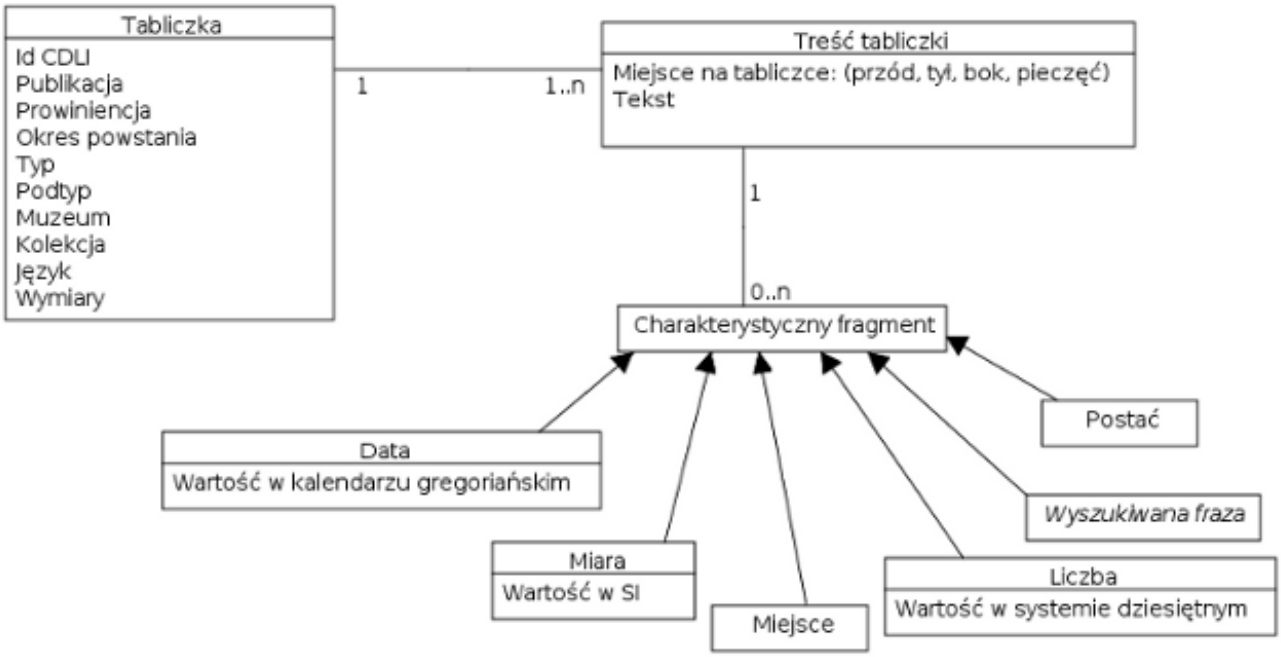

Rysunek 3.2: Co powinna zawierać tabliczka w formie elektronicznej

Rozdział 4

Definicja języka TQL

4.1. Gramatyka

4.1.1. Struktura leksykalna

String

Literał ⟨*String*⟩ ma postać "x", gdzie x jest dowolnym ciągiem znaków poza " niepoprzedzonymi \.

Słowo Od Litery

Literał ⟨*Słowo Od Litery*⟩ to ciąg liter, cyfr oraz znaków - _ ', zaczynający się od litery, z wyjątkiem słów kluczowych.

Słowo Od Liczby

Literał ⟨*Słowo Od Liczby*⟩ to ciąg liter, cyfr oraz znaków - _ ', zaczynający się od cyfry.

4.1.2. Słowa kluczowe

```
as      define  in
search
```

4.1.3. Znaki specjalne

```
\n  :    +
/   --   *
(   )
```

4.1.4. Komentarze

W chwili obecnej język nie zawiera komentarzy.

4.1.5. Struktura syntaktyczna języka

Nieterminale są pomiędzy ⟨ a ⟩. Symbole ::= (produkcja), | (lub) i ϵ (pusta reguła) należą do notacji BNF. Wszystkie pozostałe symbole to terminale.

⟨*Zapytanie Złożone*⟩ ::= ⟨*Lista Zapytań*⟩

⟨*Zapytanie*⟩ ::= ⟨*Lista Linii Zapytania*⟩ ⟨*Lista Pustych Linii*⟩
| `define \n` ⟨*Zapytanie*⟩ `as` ⟨*Nazwa*⟩ ⟨*Lista Pustych Linii*⟩
| `search \n` ⟨*Zapytanie*⟩ `in` ⟨*Nazwa*⟩ ⟨*Lista Pustych Linii*⟩
| ⟨*Lista Pustych Linii*⟩

⟨*Linia Zapytania*⟩ ::= ⟨*Identyfikator*⟩ `:` ⟨*Wyrażenie*⟩

⟨*Wyrażenie*⟩ ::= ⟨*Wyrażenie*⟩ + ⟨*Wyrażenie1*⟩
| ⟨*Wyrażenie*⟩ `/` ⟨*Wyrażenie1*⟩
| ⟨*Wyrażenie1*⟩

⟨*Wyrażenie1*⟩ ::= −− ⟨*Wyrażenie1*⟩
| ⟨*Wyrażenie2*⟩

⟨*Wyrażenie2*⟩ ::= ⟨*Tekst*⟩ `*` ⟨*Tekst*⟩
| ⟨*Tekst*⟩ `*`
| `*` ⟨*Tekst*⟩
| ⟨*Tekst*⟩
| `(` ⟨*Wyrażenie*⟩ `)`

⟨*Lista Zapytań*⟩ ::= ⟨*Zapytanie*⟩
| ⟨*Zapytanie*⟩ ⟨*Lista Zapytań*⟩

⟨*Lista Linii Zapytania*⟩ ::= ⟨*Linia Zapytania*⟩ `\n`
| ⟨*Linia Zapytania*⟩ `\n` ⟨*Lista Linii Zapytania*⟩

⟨*Pusta Linia*⟩ ::= `\n`

⟨*Lista Pustych Linii*⟩ ::= ϵ
| ⟨*Pusta Linia*⟩ ⟨*Lista Pustych Linii*⟩

⟨*Tekst*⟩ ::= ⟨*String*⟩
| ⟨*Słowo*⟩

⟨*Słowo*⟩ ::= ⟨*Słowo Od Litery*⟩
| ⟨*Słowo Od Liczby*⟩

⟨*Identyfikator*⟩ ::= ⟨*Słowo Od Litery*⟩

⟨*Nazwa*⟩ ::= ⟨*String*⟩

4.2. Semantyka

Przedstawimy semantykę na wybranych przykładach.

4.2.1. Zapytania proste

```
provenience: Gar*
period: "Ur III"
genre: Administrative
text: udu + (masz2/ugula) --szabra
```

Wynikiem zapytania będą wszystkie tabliczki, które:

- pochodzą z miejscowości o nazwie zaczynającej się na “Gar”
- pochodzą z okresu Ur III
- są dokumentami administracyjnymi
- zawierają słowo “udu” oraz conajmniej jedno ze słów “masz2” lub “ugula”
- nie zawierają słowa “szabra”

4.2.2. Zapytania złożone

```
provenience: Ur
period: "Ur III"/"Ur IV"
text: udu --szabra

text: masz2/ugula
publication: tan*
provenience: Ur
```

Wynikiem zapytania będą wszystkie tabliczki, które:

- pochodzą z miejscowości Ur
- pochodzą z okresu Ur III lub Ur IV
- zawierają słowo “udu”
- nie zawierają słowa “szabra“

oraz wszystkie tabliczki, które:

- zawierają słowo ”masz2“ lub ”ugula“
- zostały opublikowane w publikacji, której nazwa zaczyna się od ”tan“
- pochodzą z miejscowości Ur

4.2.3. Zapytanie zdefiniowane

```
 define
  provenience: Garshana
  period: Ur III
  text: "udu ban"/mash2
as "zwierzaki w Garshana"
```

Wynikiem zapytania (po jego wywołaniu) będą wszystkie tabliczki, które:

- pochodzą z miejscowości Garshana
- pochodzą z okresu Ur III
- zawierają conajmniej jedną z fraz ”udu ban“ lub ”mash2“

4.2.4. Wywołanie zapytania zdefiniowanego

```
search
  text: adad-tilati
in "zwierzaki w Garshana"
```

Wynikiem zapytania będą wszystkie tabliczki, które:

- spełniają wszystkie warunki zapytania "zwierzaki w Garshana"
- zawierają słowo "adad-tilati"

Rozdział 5

Implementacja

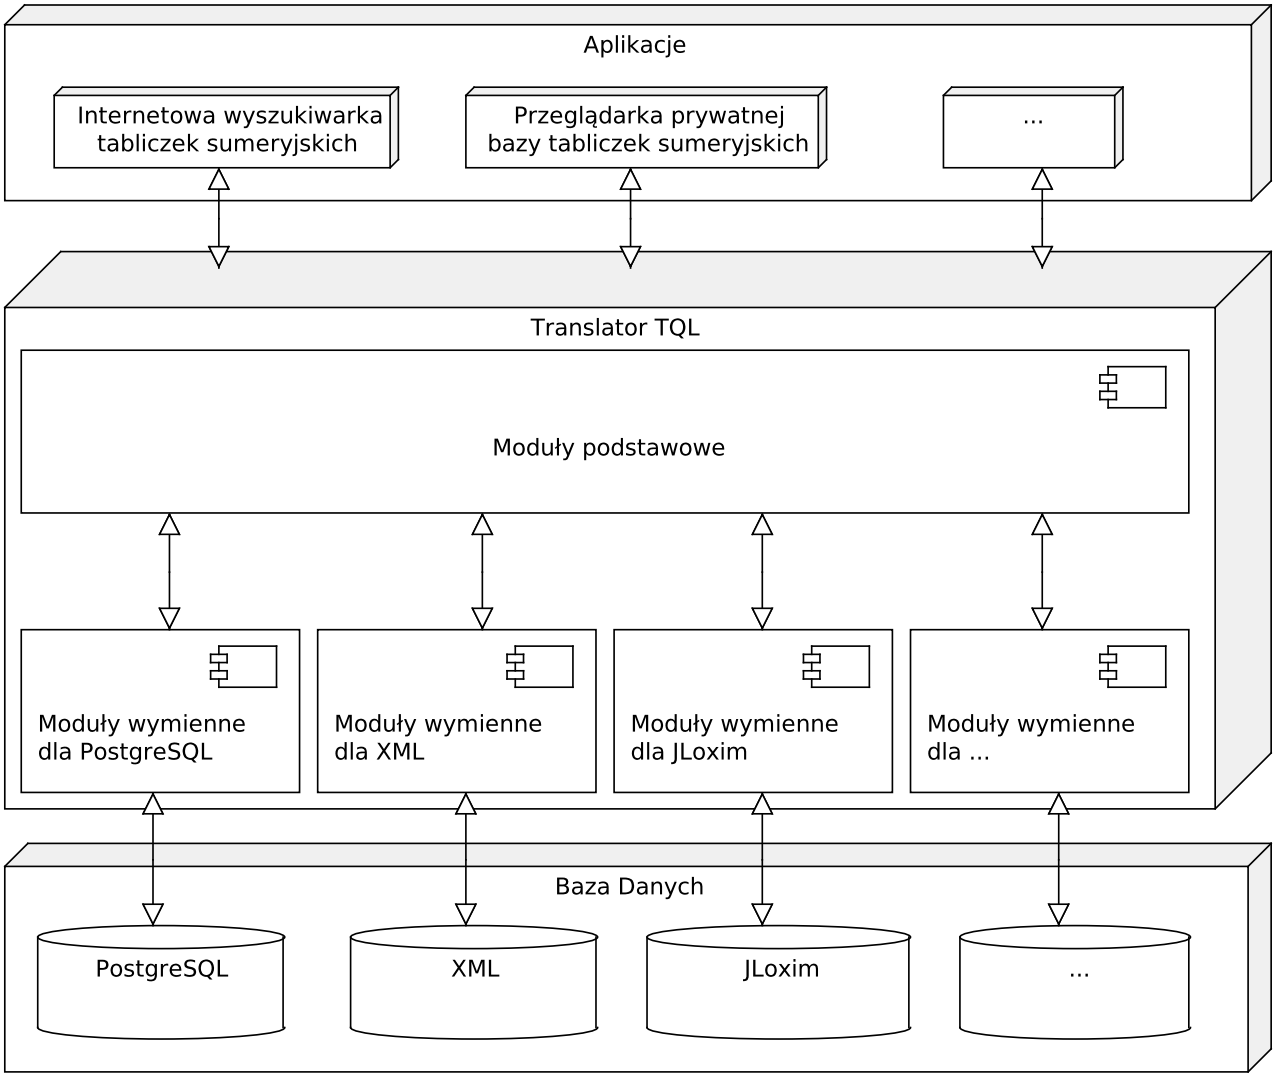

Rysunek 5.1: Struktura systemu korzystającego z translatora

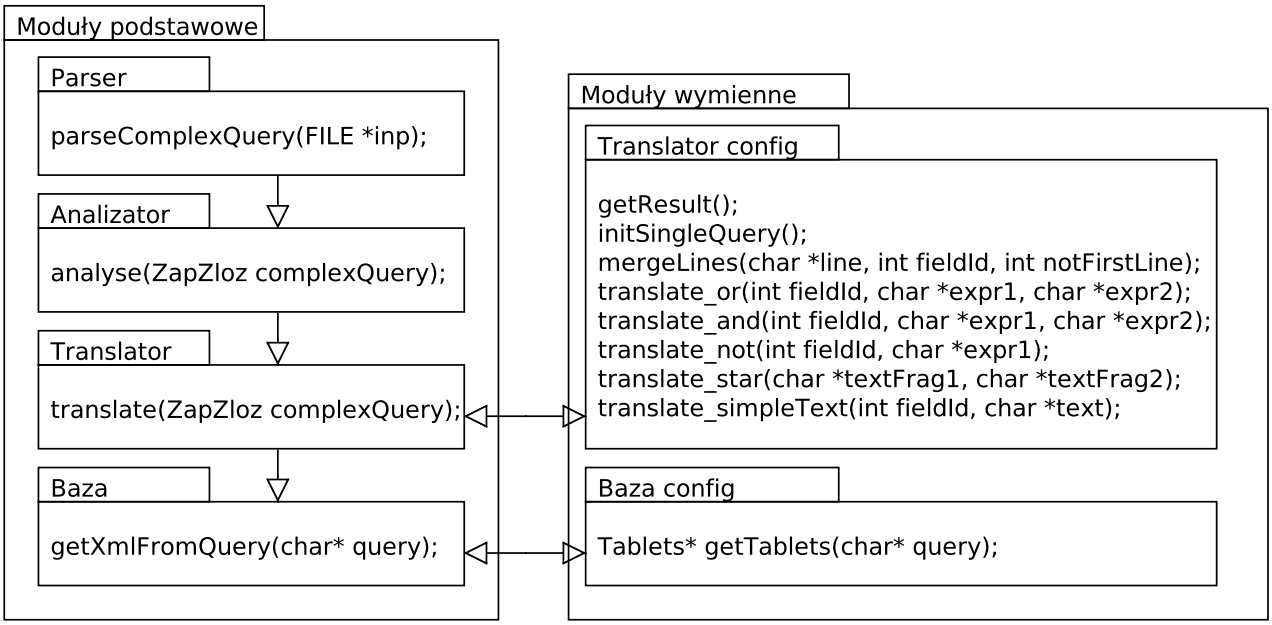

Rysunek 5.2: Podział programu na moduły

Implementacja składa się z dwóch części - modułów podstawowych (niezależnych od struktury danych) i modułów wymiennych (zależnych).

5.1. Moduły podstawowe

5.1.1. Parser

Parser został utworzony za pomocą narzędzia BNFC. Następnie został zmodyfikowany ręcznie: nazwy stałych oznaczających symbole, dodanie tablicy symboli (stringów), uporządkowanie kodu, zmiana niektórych struktur danych. Na parser składają się następujące pliki:

- Parser.c
- Parser.h
- TQL.y
- TQL.l

5.1.2. Analizator kontekstowy

- sprawdza, czy to co jest po lewej w linii zapytania jest nazwą pola.
- upraszcza zapytania - z zapytania złożonego (wywołanie search in) tworzy jedno zapytanie proste
- wypełnia strukturę danych

Składa się z następujących plików:

- Context.c
- Context.h

5.1.3. Translator

Zadaniem translatora jest przetłumaczenie struktury (drzewa składni abstrakcyjnej) jaka powstała na zapytanie w danym języku. Składa się z następujących plików:

- Translator.c
- Translator.h
- Translator_config.h
- Translator_config.c (implementacja interfejsu z Translator_config.h, zależny od wyboru bazy danych itp)

To jak poszczególne elementy są tłumaczone zależy od pliku Translator_config.c (interfejs jest w Translator_config.h). Plik Translator.c przechodzi całą strukturę i od czasu do czasu wywołuje funkcję z Translator_config.

5.1.4. Baza

Moduł bazy jest odpowiedzialny za wywołanie przetłumaczonego zapytania i przekazanie wyniku w określonej formie - w tym momencie xml. Składa się z następujących plików:

- Database.c
- Database.h
- Database_config.h
- Database_config.c (implementacja interfejsu z Database_conf.h, zależny od wyboru bazy danych itp)

Wywołuje funkcję z Database_config.h, jako parametr podaje treść zapytania, funkcja zwraca wypełnioną strukturę danych Tablets.

```
typedef struct{
    char* id;
    char* id_cdli;
    char* publication;
    char* measurements;
    char* year;
    char* provenience;
    char* period;
    char* genre;
    char* subgenre;
    char* collection;
    char* text;
    Tags *tags; //miejsca gdzie w tekście są wyniki wyszukiwania
} Tablet;
```

```
typedef struct{
    int size;
    Tablet *tabs;
} Tablets;
```

Następnie tłumaczy otrzymaną strukturę na xml-a.

5.1.5. Pliki pomocnicze

Tablica symboli (stringów):

- symbols.c
- symbols.h

Obsługa błędów:

- Err.c
- Err.h

Definicja struktur danych:

- Absyn.c
- Absyn.h

Moduł do dzielenia tekstu wg. separatora, implementacja funkcji explode z php (pobrane z internetu):

- Cexplode.c
- Cexplode.h

5.2. Moduły wymienne

Pliki zależne od wyboru konkretnej bazy danych to:

- Translator_config.c
- Database_config.c

Ich interfejs jest wspólny dla wszystkich baz danych.

5.2.1. Baza PostgreSQL

Diagram encji

Treść tabliczki jest trzymana w formie grafu (zgodnie z pomysłem dr Wojciecha Jaworskiego), którego krawędziami są odczyty i tagi (w przyszłości także kliny). Węzeł tego grafu jest liczbą w postaci:

```
<numer węzła w tabliczce> * 1 000 000 + <id tabliczki>
```

Stąd wzięły się przerywane linie na diagramie encji - nie ma bezpośredniego klucza obcego w tabeli Reading (czy Tag) do Tablet, jednak związek istnieje. Taki sposób przechowywania informacji o treści tabliczki umożliwia sprawniejsze wyszukiwanie nie tylko po odczytach (pozwala pomijać linie z uszkodzeniami) ale także w przyszłości ułatwia zaimplementowanie wyszukiwania po klinach, po tagach itp.

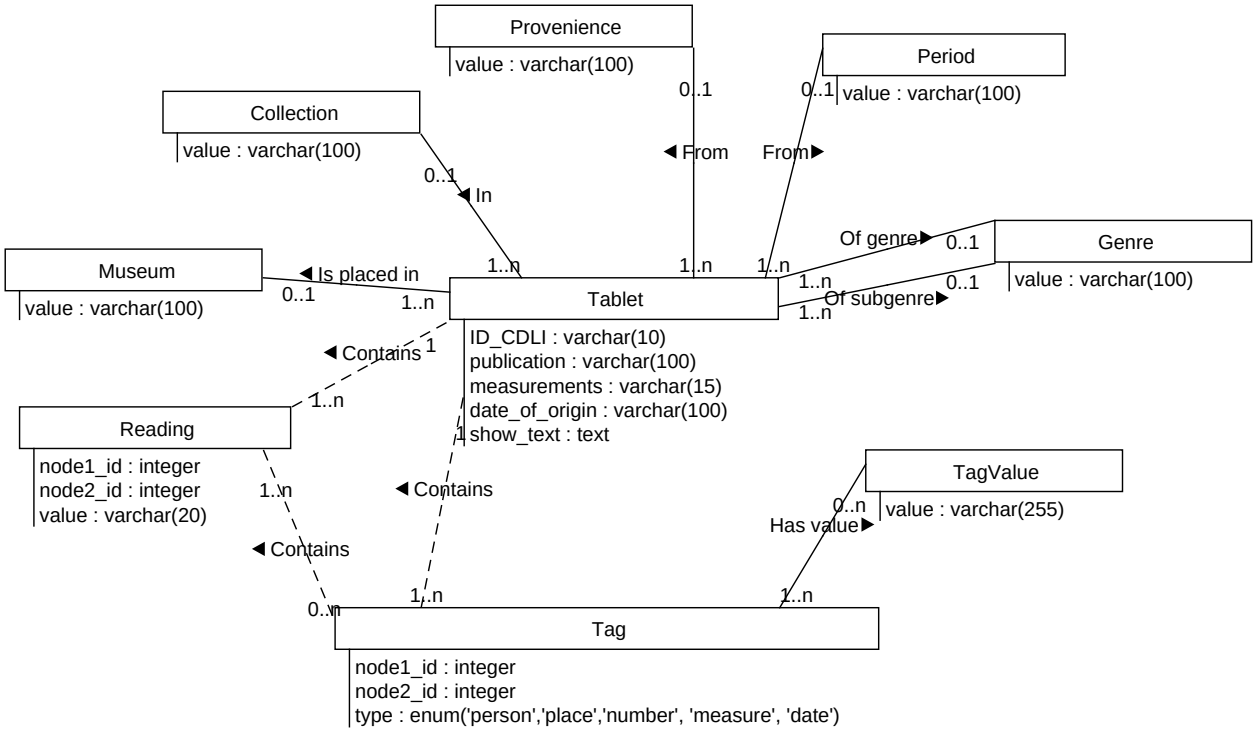

Rysunek 5.3: Diagram encji

Translator_config

Dostaje poszczególne fragmenty drzewa struktury zapytania i tłumaczy je na SQL. Przetłumaczone fragmenty zbiera do buforów (select, from, where), które następnie odpowiednio skleja. Każde proste zapytanie jest tłumaczone na jednego selecta; jak jest kilka prostych zapytań to są sklejane UNION.

Inicjalizacja zapytania

Tłumaczenie prostego zapytania zaczyna się od inicjalizacji buforów przechowujących poszczególne części wynikowego SQL-a. Select jest inicjowany na

```
SELECT t.id, t.id_cdli, t.publication, t.measurements, t.origin_date,
       p.value, pd.value as period,
       g1.value as genre, g2.value as subgenre,
       c.value as collection, t.text
```

From jest inicjowany

```
FROM tablet t
  LEFT JOIN provenience p ON p.id=t.provenience_id
  LEFT JOIN collection c ON c.id=t.collection_id
  LEFT JOIN genre g1 ON g1.id=t.genre_id
  LEFT JOIN genre g2 ON g2.id = t.subgenre_id
  LEFT JOIN period pd ON pd.id = t.period_id
```

Where jest inicjowany na

```
WHERE
```

Tłumaczenie konstrukcji prostych

Poniższe tłumaczenia są dodawane do klauzuli "where" i łączone "AND".

Konstrukcja	Tłumaczenie na SQL
provenience: wartosc	`p.value LIKE 'wartosc'`
publication: wartosc	`t.publication LIKE 'wartosc'`
period: wartosc	`pd.value LIKE 'wartosc'`
year: wartosc	`t.origin_date LIKE 'wartosc'`
genre: wartosc	`g1.value LIKE 'wartosc'` `OR g2.value LIKE 'wartosc'`
cdli_id: wartosc	`t.cdli_id LIKE 'wartosc'`

Tłumaczenie operatorów:

Operator	Tłumaczenie
/	OR
–	NOT
+	AND
*	%

Tłumaczenie konstrukcji złożonych

Została zaimplementowana tylko jedna konstrukcja złożona - przy zapytaniu o treść tabliczki (pole "text"). Korzystamy przy tym zapytaniu z przedstawienia treści tabliczki w formie grafu. Krawędziami grafu są słowa, jedyną funkcją węzłów jest zachowanie kolejności. Graf jest w tabeli readings. Id węzłów składają się z numeru tabliczki i kolejnego numeru węzła tabliczki (nr_wezla * 1 000 000 + id_tabliczki). Uznajemy, że słowa są oddzielone spacjami.

Pojawienie się wyszukiwania po treści tabliczki niesie za sobą konieczność dodania do

klauzuli "from"

```
INNER JOIN (
  <wynikowe zapytanie o treść tablczki>
) AS sequence ON sequence.id_tab = t.id
```

Natomiast do select dodajemy:

```
, sequence.nodes as nodes
```

Gdzie <wynikowe zapytanie o treść tablczki> to kombinacja zapytań typu:

```
SELECT
  id_tab,
  CAST(array_accum(nodes) as TEXT) as nodes,
  COUNT(DISTINCT id_seq) AS seq,
  <id_seq> AS id_seq
FROM (
  SELECT
    r1.node1_id % 1000000 AS id_tab,
    '{' || r1.node1_id || ',' || r<dl_sekw>.node2_id || '}' AS nodes,
    1 AS id_seq
  FROM
    readings r1
    LEFT JOIN readings r2 ON (r2.node1 = r1.node2)
    LEFT JOIN readings r3 ON (r3.node1 = r2.node2)
    ...
    LEFT JOIN readings r<dl_sekw> ON (r<dl_sekw>.node1 = r<dl_sekw-1>.node2)
 WHERE
    r1.value LIKE '<sekw[1]>'
   AND
    r2.value LIKE '<sekw[2]>'
  AND
    r3.value LIKE '<sekw[3]>'
  AND
    ...
  AND
    r<dl_sekw>.value LIKE '<sekw[<dl_sekw>]>'
 ) AS a
GROUP BY id_tab
```

Zmienne użyte w powyższym pseudo-kodzie:

id_sekw - kolejny numer sekwencji (przydatny przy bardziej skomplikowanym zapytaniu - do ich rozróżniania

dl_sekw - ilość słów składających się na wyszukiwaną sekwencję

sekw - tablica zawierająca słowa składające się na wyszukiwaną sekwencję

Operator	Tłumaczenie

/	SELECT
	  id_tab,
	  CAST(array_accum(nodes) as TEXT) as nodes,
	  COUNT(DISTINCT id_seq) as seq,
	  <id_sekw> as id_seq
	FROM
	(
	  <zapytanie1>
	  UNION
	  <zapytanie2>
	)
	as c
	GROUP BY id_tab

+	SELECT * FROM
	 (SELECT id_tab,
	  CAST(array_accum(nodes) as TEXT) as nodes,
	  COUNT(DISTINCT id_seq) as seq,
	  <id_sekw> as id_seq
	  FROM
	  (<zapytanie1>
	  UNION
	  <zapytanie2>)
	  as c
	  GROUP BY id_tab
	) as b
	WHERE b.seq=2

−	SELECT
	  id_tab,
	  '' as wezly,
	  0 as sekw,
	  <id_sekw> as id_sekw
	FROM
	(
	 (SELECT id as id_tab from tabliczka)
	 EXCEPT
	 (SELECT id_tab from
	  <zapytanie_negowane> as a
	)
	) as b

Operator	Tłumaczenie
*	%

Database_config

Odpowiada za wywołanie zapytania na konkretnej bazie. Korzysta z pliku database.conf, który zawiera dane dostępu do bazy. Korzysta z biblioteki libpq-fe.h do postgresa. Zwrócony wynik zapisuje do struktury Tablets.

5.2.2. Baza XML

Rozdział 6

Podsumowanie

Bibliografia

[Jaw1] Wojciech Jaworski, *Modelowanie tresci sumeryjskich tekstów gospodarczych z epoki Ur III*, http://nlp.ipipan.waw.pl/NLP-SEMINAR/071119.pdf, 19 listopada 2007

Spis rysunków